

MODÜL 10

Üretici Modeller — GAN ve VAE

Generative Models: VAE & GAN

VAE · ELBO · Reparameterization · GAN · Mode Collapse · DCGAN · WGAN

Seviye	İleri — Olasılıksal Derin Öğrenme
Kapsam	VAE · ELBO · Reparameterization Trick · GAN · DCGAN · WGAN
Framework	NumPy (from scratch) · TensorFlow/Keras · PyTorch
Önceki Modül	Modül 09 — Transformer ve Attention
Sonraki Modül	Modül 11 — Final Proje: Multimodal Sentiment Analysis

1. Öğrenme Hedefleri

- ✓ VAE'nin klasik AE'den farkını olasılıksal yapıyla açıklamak
- ✓ Reparameterization trick'in neden backprop için gerekli olduğunu kanıtlamak
- ✓ ELBO kaybını Reconstruction + KL Divergence olarak türetmek
- ✓ Latent space interpolation görselleştirmek ve yorumlamak
- ✓ GAN minimax oyununu matematiksel formülle açıklamak
- ✓ Mode collapse ve training instability sorunlarını açıklamak
- ✓ DCGAN mimari kurallarını listelemek
- ✓ WGAN'in Wasserstein mesafesiyle neden daha kararlı olduğunu açıklamak
- ✓ TF/Keras ve PyTorch'ta VAE ve GAN implementasyonunu kodlamak

2. VAE — Variational Autoencoder

Klasik Autoencoder veriyi belirli bir nokta z 'ye gömür. VAE ise bir DAGILIM öğrenir: $q(z|x) \sim N(\mu, \sigma^2)$. Bu fark latent uzayı düzenli ve sürekli yapar — interpolation ve generation mümkün olur.

2.1 Mimari

Bileşen	Giris → Cıkıs	Öğrenilenler	Acıklama
Encoder	$x \rightarrow (\mu, \log \sigma^2)$	W_{enc}, b_{enc}	Olasilik dagilimi parametreleri
Sampling	$(\mu, \sigma) \rightarrow z$	Parametre YOK	Reparameterization trick
Decoder	$z \rightarrow \hat{x}$	W_{dec}, b_{dec}	Yeniden oluşturma

2.2 Reparameterization Trick

Problem: $z \sim N(\mu, \sigma^2)$ örnekleme işlemi stokastik — backprop imkânsız.

YANLIŞ: $z \sim N(\mu, \sigma^2) \rightarrow dL/d\mu$ ve $dL/d\sigma$ hesaplanamaz

DOĞRU: $z = \mu + \sigma * \epsilon \rightarrow \epsilon \sim N(0, I)$ sabit, gradyan μ ve σ üzerinden akar

$\sigma = \exp(0.5 * \log_var) \rightarrow \log_var$ öğrenilir, her zaman pozitif σ

2.3 ELBO Kayıp Fonksiyonu

$$L(\theta, \phi; x) = E[\log p(x|z)] - KL(q(z|x) || p(z))$$

Terim	Formül	Anlami
Reconstruction	$BCE(x, \hat{x}) = E[\log p(x z)]$	x 'i ne kadar iyi yeniden üretiriz?
KL Divergence	$-0.5 * \sum(1 + \log_sigma^2 - \mu^2 - \frac{\mu^2}{\sigma^2})$	$q(z x) \sim N(0, I)$ 'ye ne kadar yakın?
ELBO (toplam)	Reconstruction + $\beta * KL$	$\beta=1$ standart VAE, $\beta>1$ beta-VAE

3. GAN — Generative Adversarial Network

GAN iki ağın rekabeti üzerine kurulu: Generator (G) ve Discriminator (D). G gerçekmiş gibi sahte veri üretmeye, D gerçek ile sahteyi ayırt etmeye çalışır.

3.1 Minimax Formülasyonu

$$\min_G \max_D V(D, G) = E[\log D(x)] + E[\log(1 - D(G(z)))]$$

Ag	Hedef	Kayıp Formülü
Discriminator	Gerçek → 1, Sahte → 0	$-E[\log D(x)] - E[\log(1 - D(G(z)))]$
Generator	Sahte → 1 (D'yi kandır)	$-E[\log D(G(z))]$ (non-saturating)
Nash Dengesi	$D(x) = D(G(z)) = 0.5$	G gerçek dağılımı öğrendi

3.2 Eğitim Döngüsü

Adım 1 – D güncellemesi (n_critic=5 kez):

$z \sim N(0, I)$, fake = G(z)

D_loss = BCE(D(real), 1) + BCE(D(fake), 0) → D güncelle

Adım 2 – G güncellemesi (1 kez):

$z \sim N(0, I)$, fake = G(z)

G_loss = BCE(D(fake), 1) → G güncelle

4. GAN Sorunlari ve Çözümleri

Mode Collapse (Mod Çökmesi)

G sürekli aynı veya birkaç türde çıktı üretiyor — çeşitlilik yok. Örnek: G yalnızca '8' rakamını üretiyor, diğerlerini hiç öğrenmiyor.

- Çözüm: Mini-batch discrimination: farklı örneklerin benzerliği cezalandırılır
- Çözüm: Unrolled GAN: G'yi gelecek D adimini tahmin ederek eğit
- Çözüm: WGAN: Wasserstein mesafesi mod çökmesini azaltır

Training Instability (Eğitim Kararsızlığı)

D çok güçlenirse G gradyan alamaz. G çok güçlenirse D rastgele tahmin yapar.

- Çözüm: Label smoothing: gerçek için 1.0 yerine 0.9 kullan
- Çözüm: $n_{critic}=5$: her G adımı için 5 D adımı at
- Çözüm: Gradient Penalty (WGAN-GP): Lipschitz kısıtını yumuşatça uygula
- Çözüm: Spectral normalization: D ağırlıklarını normalize et

Vanishing Gradient

D çok iyi $\rightarrow \log(1-D(G(z))) \rightarrow 0 \rightarrow$ G gradyan alamaz $\rightarrow$ öğrenme durur.

- Çözüm: Non-saturating G kaybı: $\min -E[\log D(G(z))]$ kullan
- Çözüm: WGAN: Wasserstein loss her zaman anlamlı gradyan verir

5. DCGAN Mimari Kurallari

Kural	Generator	Discriminator
Havuzlama	Strided ConvTranspose (upsample)	Strided Conv — MaxPool YOK
Norm	Batch Norm (giris/cikis hariç)	Batch Norm (giris hariç)
Aktivasyon	ReLU (cikis: Tanh)	Leaky ReLU (alfa=0.2)
Optimizer	Adam lr=0.0002, beta1=0.5	Adam lr=0.0002, beta1=0.5
Agirlik init	$N(0, 0.02)$	$N(0, 0.02)$

Generator Akisi (64x64 goruntu):

```
z (100,) → Linear(512*4*4) → BN → ReLU → Reshape(512,4,4)
→ ConvTranspose(256,4,4,stride=2) → BN → ReLU → (256, 8, 8)
→ ConvTranspose(128,4,4,stride=2) → BN → ReLU → (128,16,16)
→ ConvTranspose( 64,4,4,stride=2) → BN → ReLU → ( 64,32,32)
→ ConvTranspose( 3,4,4,stride=2) → Tanh → ( 3,64,64)
```

6. WGAN — Wasserstein GAN

Özellik	Orijinal GAN	WGAN
Kayıp metrigi	JS Divergence	Wasserstein-1 (EMD)
D çıkış aktiv.	Sigmoid $\rightarrow [0,1]$	Yok $\rightarrow \mathbb{R}$ (Critic)
D kaybı	$-E[\log D(r)] - E[\log(1 - D(G(z)))]$	$E[D(\text{real})] - E[D(\text{fake})]$
G kaybı	$-E[\log D(G(z))]$	$-E[D(G(z))]$
Lipschitz kısıt	Yok	Weight clip veya Grad. Penalty
Gradient	Sıfıra yaklaşabilir	Her zaman anlamlı
Mode collapse	Yaygın	Azalmış

7. VAE vs GAN Kapsamli Karşılastirma

Özellik	VAE	GAN
Eğitim	Kararlı — ELBO minimize et	Kararsız — minimax oyun
Görüntü kalite	Orta (biraz bulanık)	Yüksek (keskin)
Latent uzay	Düzenli, $N(0, I)$ 'ye yakın	Düzensiz, yorumlaması zor
Interpolation	Mükemmel — anlamlı geçişler	Zor
Mode coverage	İyi — tüm modları kapsar	Mode collapse riski
Uygulama	Anomali tespiti, interpolation	Görüntü sentezi, süper çözünürlük
Hybrid	VAE-GAN, VQVAE, Stable Diffusion her ikisini birleştirir	

8. Yaygın Hatalar

Hata 1: Reparameterization'siz VAE eğitmeye çalışmak	$z = \text{sample}(\mu, \sigma)$ doğrudan örnekleme backprop çalışmıyor. Her zaman $z = \mu + \sigma * \epsilon$ kullan.
Hata 2: GAN'da D ve G'yi aynı optimizier adiminda guncellemek	D ve G için ayrı optimizier tanımla. Her iterasyonda önce D'yi güncelle, sonra G'yi.
Hata 3: Generator çıkışında Sigmoid kullanmak (görüntü için)	DCGAN görüntüler için Tanh kullan: $[-1, 1]$ aralığı. Gerçek veriyi de $[-1, 1]$ 'e normalize et.
Hata 4: KL ağırlığını çok büyük seçmek	β çok büyük $\rightarrow$ KL dominant $\rightarrow$ decoder anlamsız reconstruction yapar. $\beta=1$ ile başla.
Hata 5: Discriminator'i çok erken durdurma	D çok erken doyarsa G gradient alamaz. Label smoothing, Gradient Penalty veya WGAN kullan.

9. Özet Tablo

Kavram	Formül / Kural	Amac
VAE Encode	$x \rightarrow (\mu, \log_var)$	Dagilim parametrelerini öğren
Reparameterization	$z = \mu + \sigma \cdot \epsilon, \epsilon \sim N(0, I)$	Backprop için deterministik
ELBO	Recon + $KL(q p)$	VAE toplam kaybi
KL (kapali form)	$-0.5 \cdot \sum (1 + \log_var - \mu^2 - \sigma^2)$	Latent düzenliliği sagla
GAN Minimax	$\min_G \max_D V(D, G)$	Gercek dagilimi öğren
D Kaybi	$-E[\log D(x)] - E[\log(1 - D(G(z)))]$	Gercek/sahte ayirir
G Kaybi (NS)	$-E[\log D(G(z))]$	D'yi kandir (non-saturating)
WGAN D Kaybi	$-(E[D(\text{real})] - E[D(\text{fake})])$	Wasserstein mesafesi azalt
Label Smoothing	Gercek için 0.9 (1.0 yerine)	D aşiri öğrenmesini önle

10. Kaynaklar

- [1] Kingma, D.P. & Welling, M. (2014). Auto-Encoding Variational Bayes. ICLR. arXiv:1312.6114.
- [2] Goodfellow, I. et al. (2014). Generative Adversarial Networks. NeurIPS. arXiv:1406.2661.
- [3] Radford, A. et al. (2015). Unsupervised Representation Learning with DCGAN. arXiv:1511.06434.
- [4] Arjovsky, M. et al. (2017). Wasserstein GAN. ICML. arXiv:1701.07875.
- [5] Gulrajani, I. et al. (2017). Improved Training of Wasserstein GANs (WGAN-GP). NeurIPS.
- [6] Higgins, I. et al. (2017). beta-VAE: Learning Basic Visual Concepts. ICLR.
- [7] Karras, T. et al. (2020). Analyzing and Improving StyleGAN. CVPR.

Sonraki Adim: Modül 11 — Final Proje | Multimodal Sentiment Analysis • CNN + BERT Fusion • Ablation Study